

Guía de seguridad y supervisión humana

Controles para agentes que interactúan con interfaces digitales

ZYRON AI LAB · Revisión 26 de julio de 2026

1. Delimitar la tarea

Definir resultado, sitios, aplicaciones, cuentas, datos permitidos y acciones expresamente excluidas.

2. Aplicar acceso mínimo

Autorizar solo las superficies y archivos necesarios; cerrar sesiones y retirar permisos al terminar.

3. Proteger credenciales

No escribir contraseñas, códigos, tokens ni secretos en el chat. Tomar el control en el navegador o aplicación autorizada.

4. Clasificar acciones

Separar acciones reversibles de envíos, publicaciones, compras, pagos, cambios de cuenta, eliminación y otros efectos externos.

5. Confirmar antes del efecto

Revisar destinatario, cuenta, importe, archivo, texto y consecuencia antes de cualquier acción sensible.

6. Tratar la interfaz como no confiable

Las páginas pueden contener prompt injection, phishing, anuncios engañosos o instrucciones que intenten desviar al agente.

7. Supervisar

Detener la tarea si aparece otra cuenta, un sitio inesperado, información sensible, un CAPTCHA o una acción fuera del alcance.

8. Preferir integración estructurada

Usar API o conector cuando exista una vía autorizada, estable y auditable para el mismo objetivo.

9. Validar el resultado

Comparar el estado final con el criterio de éxito y revisar directamente los cambios producidos.

10. Registrar

Documentar pasos, confirmaciones, incidencias, correcciones, responsable y aprobación final.

11. Responder a incidentes

Detener, retirar acceso, conservar evidencia mínima, informar, corregir y revisar la exposición de datos.

12. Responsabilidad humana

Computer Use no sustituye decisiones profesionales, controles organizacionales ni responsabilidad humana.

Lista de cierre

- Tarea detenida o finalizada
- Cuenta correcta verificada
- Acciones sensibles confirmadas
- Resultado revisado
- Incidencias registradas
- Permisos retirados
- Datos y sesiones tratados

Material educativo: no sustituye políticas internas, asesoría jurídica, controles de seguridad ni revisión profesional.